

Final Project

學號：R07521523 姓名：劉錦鴻

學號：R07521529 姓名：吳欣璇

學號：R07521526 姓名：林亭佑

1. Task1 (鋼筋總支數)

a. (1%) 請說明如何進行資料前處理 (label、image pre-processing)

● Label

當我們在處理 label 的過程中，始終對於某些鋼筋是否應該被認定為鋼筋數量感到兩難。除了助教在起初所提及的搭接與束筋，被圖片邊界切割的鋼筋又應當以何種依據作為認定的標準。因此我們藉由類似 ensemble 的方法，透過兩到三個人的投票來決定是否納入該鋼筋，假定觀察者正確辨識的能力都大於 0.5，因此我們相信可以得出更理想的 label 結果。

● Image pre-processing

在進行若干次測試 (Testing) 後，我們發現 Testing Data 與 Training Data 有相當的差異，且 Training Data 存在嚴重的 imbalance 問題，因此我們針對 Total Rebars 介於 20~30 之間的圖片，進行 90 度的旋轉，讓 Training Data 增加了 306 張圖片。

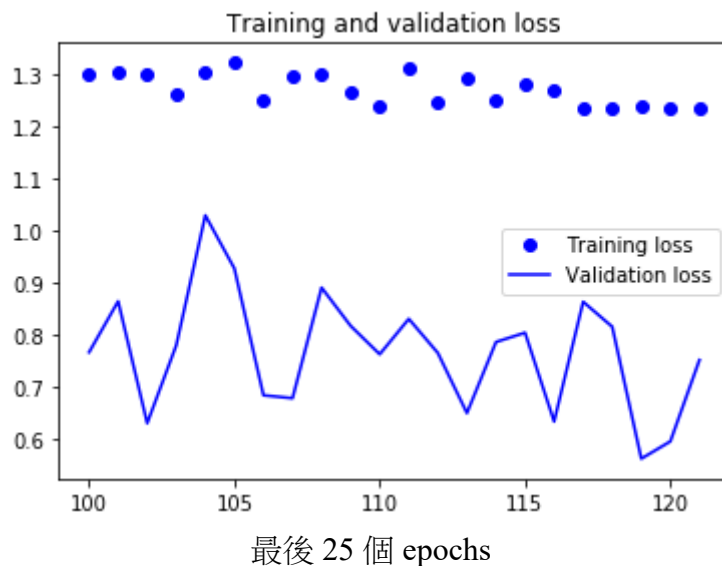

b. (1%) 請說明使用的 Model 架構，畫出 Training/Validation loss history，並加以簡單說明。

● Model

利用 ResNet50v2 作為 pre-trained 之 model，並在後續加上兩層 Fully-Connected (FC) 層以及一層 Dropout 層 (dropout rate = 0.3) 一起進行訓練，將 RMSE 作為 loss function，optimizers 則採用 RMSprop。

Layer (type)	Output Shape	Param #
resnet50v2 (Model)	(None, 5, 5, 2048)	23564800
flatten_1 (Flatten)	(None, 51200)	0
dense_1 (Dense)	(None, 512)	26214912
dense_2 (Dense)	(None, 512)	262656
dropout_1 (Dropout)	(None, 512)	0
dense_3 (Dense)	(None, 1)	513
Total params: 50,042,881		
Trainable params: 49,997,441		
Non-trainable params: 45,440		

● Training/Validation loss history



c. (1%) Experiment and Discussion (討論一些嘗試與結果)

起初主要的嘗試為不同的 pre-train model，例如 VGG、Resnet 等等，並透過 Frozen 與 Unfrozen 的方式分別將其與原模型結合，來找出最理想的模型架構。原模型的網絡層數、dropout 的不同比例，也會對模型的精準度有不小的影響。另一方面，也透過調整圖像預處理 (ImageDataGenerator) 的不同參數：如 Batch_size 或 target_size 等等，來檢視模型的預測效能。Data augmentation (資料增強) 則同樣帶給模式一定程度的幫助，利用隨機機率的旋轉、調整大小、比例尺寸甚至亮度等等，以創造更多的圖片來讓機器學習，彌補某些特定資料的缺陷或不足。

我們曾經嘗試將資料預測分成預測水平與鉛直鋼筋數量，並透過上述的不同種模型進行測試，最後在將兩者的數量進行加總，結果發現僅有水平鋼筋數量較能有精準的預測，鉛直鋼筋則較難以預測。有鑒於此，希望可以提升訓練資料集對鉛直鋼筋的辨識能力，因此，透過額外的人工觀察，比對測試資料集與訓練資

料集的差異，檢視 test image 中鋼筋位置的特性，進而 label 更多有相似形式的 train image，來建立囊括更多圖片特性的訓練資料集，確保模型有更完整的訓練過程，在沒有多 label 的情況下，MSE 僅能降低至約 1.59 左右，而新增 label 後同樣 model 則可降至 1.18 左右，結果證實確實能有效提高模型預測的精確度。

2. Task2 (裂縫破壞模式)

a. (1%) 請說明如何進行資料前處理 (image pre-processing)

- Image pre-processing :

將訓練資料利用 ImageDataGenerator 進行 Data Augmentation(其中調整之參數含 rotation_range = 15, shear_range = 0.1, zoom_range = 0.2, horizontal_flip = True), 並將 target size 設為 150*150, 且為了後續模型運算時間考量, 將 batch size 設為 10, 使運算速度增快。

b. (1%) 請說明使用的 Model 架構，畫出 Training/Validation loss history，並加以簡單說明。

- Model


利用 Xception 作為 pre-trained 之 model, 並在後續加上三層 FC 層一起進行訓練, 將 binary_crossentropy 作為 loss function, optimizers 則採用 RMSprop, 總共訓練 50 個 epoches。

Model: "sequential_2"


Layer (type)	Output Shape	Param #
xception (Model)	(None, 5, 5, 2048)	20861480
flatten_2 (Flatten)	(None, 51200)	0
dense_5 (Dense)	(None, 512)	26214912
dropout_4 (Dropout)	(None, 512)	0
dense_6 (Dense)	(None, 512)	262656
dropout_5 (Dropout)	(None, 512)	0
dense_7 (Dense)	(None, 512)	262656
dropout_6 (Dropout)	(None, 512)	0
dense_8 (Dense)	(None, 1)	513

=====
 Total params: 47,602,217
 Trainable params: 47,547,689
 Non-trainable params: 54,528
 =====

- Training/Validation Loss History



- Training/Validation Accuracy History



c. (1%) Experiment and Discussion (討論一些嘗試與結果)

嘗試不同的 pre-train model 來比較其預測能力，並比較 Frozen 與 Unfrozen 的方式分別將其與原模型結合，找出最理想的模型架構。原模型的網絡層數、dropout 的不同比例，也會對模型的精準度有不小的影響。另一方面，也透過調整圖像預處理 (ImageDataGenerator) 的不同參數：如 Batch_size 或 target_size 等等，來檢視模型的預測效能。Data augmentation (資料增強) 則同樣帶給模式預測一定的幫助，利用隨機機率的旋轉、調整大小、比例尺寸以及亮度等等，以創造更多的圖片來讓機器學習，彌補某些特定資料的缺陷或不足。